

# Métodos tabulares para aprendizaje por refuerzo

## Segunda parte

Lorenzo Madow

[lawrence@lcc.uma.es](mailto:lawrence@lcc.uma.es)

Universidad de Málaga



# Fuentes principales

- “Reinforcement Learning. An introduction” R.S. Sutton & A. G. Barto. The MIT Press (1998). Capítulos 4 y 6.
- “Artificial Intelligence: a modern approach” S. Russell & P. Norvig. Pearson (3<sup>a</sup> ed.) (2010). Capítulos 17 y 21.

# Breve Índice

- Introducción
- Programación dinámica
  - Evaluación de políticas
  - Mejora de políticas
- Aprendizaje por diferencias temporales
  - Algoritmo TD(0)
  - Algoritmo Q-learning

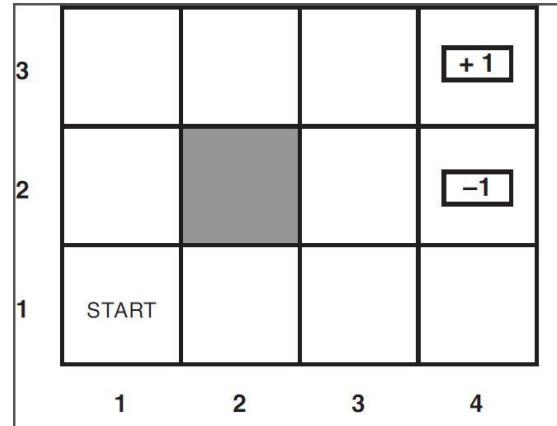
# Diferencias temporales

- El aprendizaje por diferencias temporales permite resolver un problema de decisión markoviano,:
  - a) A partir de **experiencia** en el entorno.
  - b) Cuando no disponemos de un **modelo** de la dinámica del entorno -  $p(s'/s,a)$

# Diferencias temporales

- Supongamos que partimos de una política  $\pi$  arbitraria y nuestro agente se desenvuelve en el entorno.
- Llamaremos **episodio** a una secuencia alterna de estados y acciones que acaba en un estado final.

# Diferencias temporales



Algunos episodios podrían ser:

$(1,1) \uparrow (1,2) \uparrow (1,2) \uparrow (1,3) \rightarrow (2,3) \rightarrow (3,3) \rightarrow (3,2) \uparrow (3,3) \rightarrow (4,3)$

$(1,1) \uparrow (2,1) \rightarrow (3,1) \uparrow (3,2) \uparrow (3,3) \rightarrow (4,3)$

...

Imagen: Russell & Norvig. AIMA

# Diferencias temporales

- Al igual que en el caso de la programación dinámica, estudiaremos cómo **evaluar** una política y cómo **mejorarla**, aunque esta vez sin utilizar un modelo, y únicamente a partir de la experiencia disponible.
- Iteración de políticas:

$$\pi_0 \rightarrow v_0 \rightarrow \pi_1 \rightarrow v_1 \rightarrow \dots \pi_* \rightarrow v_*$$

# Algoritmo TD(0)

- El método TD(0) permite **aproximar el valor** de un estado cada vez que un episodio pasa por el. Sea  $S_t$  el estado visitado en el paso  $t$  de un episodio, y  $S_{t+1}$  el siguiente estado visitado.

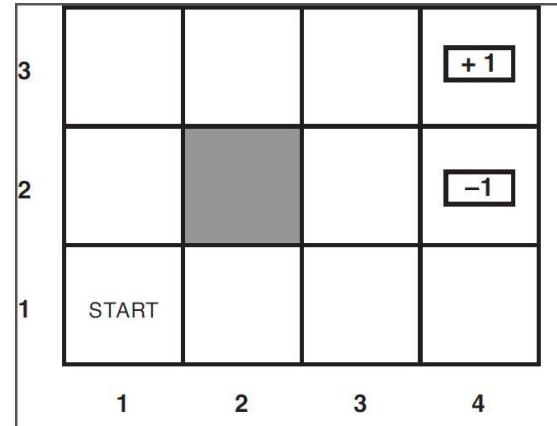
$$V(S_t) \leftarrow V(S_t) + \alpha[R_{t+1} + \gamma V(S_{t+1}) - V(S_t)]$$

# Algoritmo TD(0)

$$V(S_t) \leftarrow V(S_t) + \alpha[R_{t+1} + \gamma V(S_{t+1}) - V(S_t)]$$

Supongamos que en un momento dado

$$\begin{aligned}V(1,1) &= 0.400 \\V(1,2) &= 0.550\end{aligned}$$



Al realizar la transición de (1,1) a (1,2):

$$V(1,1) \leftarrow 0.400 + 0.1[-0.04 + 0.550 - 0.400] = 0.411$$

(1,1)  $\uparrow$  (1,2)  $\uparrow$  (1,2)  $\uparrow$  (1,3)  $\rightarrow$  (2,3)  $\rightarrow$  (3,3)  $\rightarrow$  (3,2)  $\uparrow$  (3,3)  $\rightarrow$  (4,3)

Imagen: Russell & Norvig. AIMA

# Algoritmo TD(0)

$$V(S_t) \leftarrow V(S_t) + \alpha[R_{t+1} + \gamma V(S_{t+1}) - V(S_t)]$$

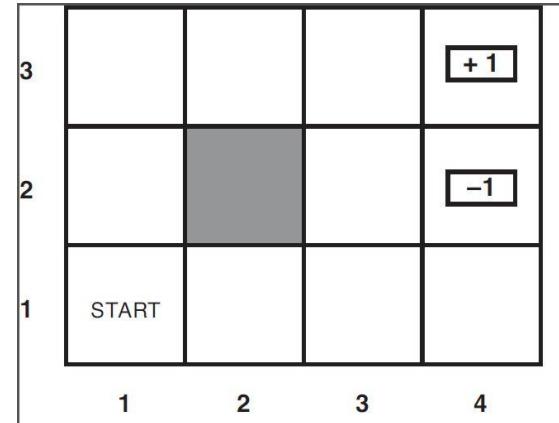
Supongamos que al inicial el segundo episodio tenemos:

$$V(1,1) = 0.411$$

$$V(2,1) = 0.300$$

....

$$V(1,1) \leftarrow 0.411 + 0.1[-0.04 + 0.300 - 0.411] = 0.3959$$



(1,1)  $\uparrow$  (2,1)  $\rightarrow$  (3,1)  $\uparrow$  (3,2)  $\uparrow$  (3,3)  $\rightarrow$  (4,3)

Imagen: Russell & Norvig. AIMA

# Algoritmo TD(0)

- Esto nos permite **evaluar** una política, pero para **mejorarla** seguiríamos necesitando un modelo de la dinámica del entorno.

$$\pi'(s) = \operatorname{argmáx}_{a \in A(s)} \sum_{s'} p(s'/s, a) \underline{v_\pi(s')}$$

- Una posibilidad es aprender también el modelo –  $p(s'/s, a)$

# Breve Índice

- Introducción
- Programación dinámica
  - Evaluación de políticas
  - Mejora de políticas
- Aprendizaje por diferencias temporales
  - Algoritmo TD(0)
  - Algoritmo Q-learning

# Algoritmo Q-learning

- Una solución alternativa es aprender el valor de las acciones, en lugar de los estados.
- Denominaremos  $Q(s,a)$  al valor esperado de realizar la acción  $a$  en el estado  $s$ .

$$V_\pi(s) = \max_{a \in A(s)} Q_\pi(s, a)$$

# Algoritmo Q-learning

- La ecuación para **aproximar** los valores de Q es análoga a la del algoritmo TD(0):

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t)]$$

- Para **seleccionar la acción** a realizar en el estado  $s$ , sólo hay que consultar los valores de  $Q(s,a)$ .

# Algoritmo Q-learning

Para asegurar una correcta convergencia, es necesario combinar de alguna manera la **explotación** del conocimiento adquirido con una **exploración** de posibilidades.

Dicho de otra manera, en la interacción con el entorno no se debe seguir siempre el dictado de la política, sino que con al menos una pequeña probabilidad, se deben explorar acciones que de otro modo no serían elegidas.

# Algoritmo Q-learning

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t)]$$

$$Q(1,1, \uparrow) = 0.4$$

$$Q(1,1, \rightarrow) = 0.3$$

$$Q(1,1, \downarrow) = 0.1$$

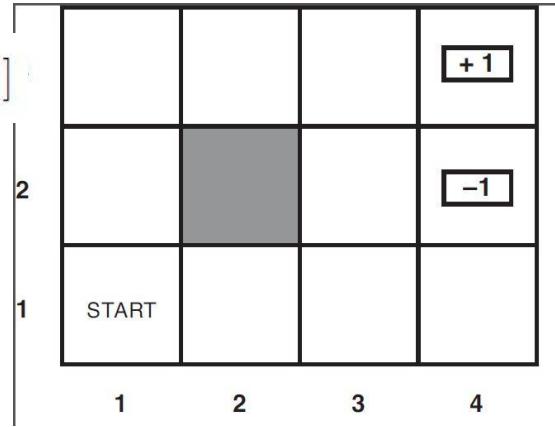
$$Q(1,1, \leftarrow) = 0.2$$

$$Q(2,1, \uparrow) = 0.6$$

$$Q(2,1, \rightarrow) = 0.3$$

$$Q(2,1, \downarrow) = 0.2$$

$$Q(2,1, \leftarrow) = 0.3$$



Ejercicio propuesto: ¿Cuál será el valor de  $Q(1,1, \uparrow)$  tras la primera transición del episodio mostrado abajo?

Suponer  $\alpha = 0,1$  y  $\gamma = 1$

(1,1)  $\uparrow$  (2,1)  $\rightarrow$  (3,1)  $\uparrow$  (3,2)  $\uparrow$  (3,3)  $\rightarrow$  (4,3)

Imagen: Russell & Norvig. AIMA

# Breve Índice

- Introducción
- Programación dinámica
  - Evaluación de políticas
  - Mejora de políticas
- Aprendizaje por diferencias temporales
  - Algoritmo TD(0)
  - Algoritmo Q-learning